



汤文

学历层次：硕士
出生年月：2002/07
个人网站：<https://tswoen.github.io/>

籍贯：安徽省，六安市
电话：13045525716
邮箱：361329@whut.edu.cn

教育背景

2024.09-2027.06	武汉理工大学(211 工程)	软件工程 (硕士)
• 学业成果：GPA 3.60/4.0，专业前 20%，硕士研究生二等学业奖学金。		
2020.09-2024.06	湖南工业大学	软件工程 (本科)
• 学业成果：GPA 3.77/4.0，专业前 10%，2024 校级奖学金。		

专业技能

语言能力：CET-6、CET-4，可流畅阅读英文技术文档。

编程基础：Python 开发，掌握数据结构与算法；了解计算机网络、操作系统基础原理，熟悉 Git、Linux 基础命令。

Agent 开发：熟练 Codex、CC，理解 CC 设计机制，掌握 CoT、ReAct、Function-Calling、MCP、Skills。

大模型：理解 Transformer 架构与 KV-Cache 原理，掌握 LoRA 轻量化微调，具备 RAG、多模态项目经验。

后端技术：掌握 MySQL 索引、事务、MVCC 机制，理解 Redis 持久化、内存淘汰、过期策略，具备性能调优能力。

实习经历

2026.06-2026.09	中兴通讯股份有限公司 数字能源研发部	AI 应用开发实习生
• 实习简介： 负责企业内部 AI 自动化工具设计开发，支撑研发协作、安全评审、技术情报分析场景开发。		
• 技术栈： Python、Skills、SubAgent、MySQL、Agent Memory、Playwright-cli		
• 核心工作：		
➢ 漏洞二次定级自动化： 基于 Skill、Playwright、REST API、代码扫描和 AI 决策树搭建 16 步 CVE 定级流程，替代跨 7 套系统的人工查询、判断和录入，单条处理效率提升约 10 倍。		
➢ 情报助手开发： 使用定时采集、信息去重、质量评估、知识入库和邮件推送链路实现多源技术情报自动沉淀，通过配置化规则与失败重试降低人工整理成本。		
➢ LLMIO VS Code 插件设计： 基于 VS Code 插件、WebView、SQL 权限表实现 API-Key 申领与模型权限管理，落地 4 层认证降级、请求幂等和缓存复用，提升内网可用性。		
• 成果收获： 接触并实践 5+Skill 流程编排、智能体开发和 VSCode 插件开发，对内部业务系统的架构设计、权限治理与生产交付建立体系化认知。		

项目经历

多智能体论文调研报告生成系统 核心开发者	2025/11-至今
• 项目地址： https://github.com/Tswoen/Paper-Agent ★ Stars: 400+ Forks:44	
• 技术栈： Python、FastAPI、LangGraph、Agent Loop、Tool-Calling、Few-shot、RAG	
• 项目背景： 针对跨领域文献调研耗时久、证据难以溯源、长任务易中断等痛点，搭建论文调研 Agent Runtime。基于 LangGraph 构建可恢复工作流，拆分检索、精读、分析、大纲与分节写作环节，实现从主题输入到综述产出的端到端自动化。	
• 核心职责：	
➢ 多 Agent 架构设计： 将论文调研拆为检索规划、论文阅读、研究分析、大纲生成、证据写作五类职责 Agent，通过阶段协作与审核反馈降低单 Agent 职责耦合和长流程输出漂移。	

- **上下文与压缩机制**：围绕长文献综述的 Token 压力，设计优先提炼摘要、全文分块、按需提取原文证据的上下文流转机制，将论文材料逐层压缩为结构化摘要、子主题分析和全局框架。
- **容错机制设计**：面向模型异常、解析失败、全文处理失败和用户中断等不确定场景，落地阶段级恢复、结构化输出重试、工具调用上限和结果持久化机制，减少小时级任务整体重跑。
- **监控与评测闭环**：建设长任务运行观测链路，记录 SSE 实时进度、Token 用量、阶段产物和异常信息，并用单元测试覆盖检索、阅读、写作、恢复续跑与前后端联调场景。
- **项目成果**：开源项目累计 Stars 400+、Forks 44；项目整体可恢复、可观测、可证据追踪的论文调研 Agent Runtime，支持检索、阅读、分析、写作多阶段产物持久化与异常续跑；通过结构化摘要、分块取证、审核修订降低长文献综述中的幻觉和引用错配风险；60 篇文献综述由人工约 2 周/份缩短至约 1 小时/份。

复杂约束条件下的文本属性抽取（天池 CCKS2026 竞赛） | 团队队长

2026.06-2026.08

- **项目地址**：<https://github.com/Tswoen/Just-Do-It> 🏆 竞赛排名：21/247
- **技术栈**：Python、LLM Agent、LoRA-SFT、vLLM、Qwen、PEFT、Transformers
- **项目背景**：CCKS2026 信息抽取竞赛，面向长文本复杂约束场景，从英文文本完成条件属性抽取并结构化输出，考验大模型语义理解与生成式抽取能力。
- **核心职责**：
 - **数据集防泄露**：按 case 维度切分训练、验证集，固定实验划分策略，规避跨集合数据泄露，保障训练、调参、评测结果可复现。
 - **SFT 微调**：基于 Qwen3-4B 开展 LoRA 轻量化微调，仅对答案部分做监督训练，提升约束抽取任务适配能力。
 - **评测闭环**：采用生成式 Micro-F1 评估回调，依据 F1 保存最优 Adapter 并启用早停，实现训练评估调参闭环。
 - **策略优化**：采用贪心+多轮采样投票生成候选结果，通过阈值调优抑制采样噪声，平衡抽取任务精度与召回。

多模态 RAG 文博知识问答系统 | 独立开发者

2025.09-2026.03

- **项目地址**：<https://github.com/Tswoen/Museum-AI>
- **技术栈**：LangChain、LangGraph、GraphRAG、Neo4j、Redis、CN-CLIP、MCP
- **项目背景**：智博 AI 是面向文博领域的多模态 RAG / GraphRAG 问答系统，围绕文博资料分散、专业内容检索门槛高、普通 RAG 易幻觉的问题，构建“文档解析、多源入库、检索增强、图谱推理、评测迭代”的完整问答链路。
- **核心职责**：
 - **文档分块与向量入库**：采用递归切分 + 语义相似度合并构建父子分块，命中子分块后返回完整父分块，并将父块控制在 2048 token 内，减少文档结构错乱和语义断裂导致的召回噪声。
 - **多策略检索机制**：落地“问题改写与意图识别、文本/图像预检索、Agent 按需调用文本库、图像库、知识图谱和 MCP 工具”的检索链路，采用源内重排、源间保留 TopK 解决异构分数不可比问题。
 - **知识图谱检索**：引入 LightRAG 自动抽取实体关系并落库 Neo4j，支持基于实体关联和多跳路径的检索补充，缓解纯向量 RAG 在复杂关系问答中的幻觉。
 - **记忆与缓存机制**：构建短期 5 轮对话记忆、长期摘要记忆和客观事实类 QA 语义缓存；结合轮次衰减、负反馈删除和动态阈值调节，兼顾多轮连贯性、响应延迟与缓存答案可靠性。
- **项目成果**：完成多模态 RAG 与 GraphRAG 全流程闭环搭建。基于自建 100 条专业测试集评测，模型上下文精确度达 74%、召回率 87%，关键信息回答准确率从 61% 提升至 82%，图文匹配余弦相似度整体提升 7%。

学生工作

科学技术协会副会长：统筹科技竞赛、技术分享类活动，安排活动全流程、人员分工，具备项目推进经验。

校团委青年传媒副部长：负责新媒体内容策划、稿件修改审核和活动宣传工作，拥有信息整理提炼与内容制作能力。

青年志愿者协会成员：参与活动前期筹备、现场执行和信息统计，管理活动物资。